Transformación y enriquecimiento de datos

Clase 8 · Analítica y Visualización de Datos

Johan Steev Muriel Mosquera

Estud-IA
HABILIDADES DIGITALES

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

Agenda del día

Horario	Actividad	Tiempo
6:30–7:00	Dudas del laboratorio anterior	30 min
7:00–8:00	Transformaciones y quizzes	60 min
8:00–8:20	Pausa	20 min
8:20–9:00	Laboratorio en Colab	40 min
9:00–9:10	Cierre y encuesta del proyecto	10 min

Objetivo y contenidos

Comprender cómo las transformaciones de columnas, las reglas de categorización y el tratamiento temporal cambian la representación y el significado analítico de los datos.

Aplicar esos principios en un proceso reproducible de preparación.

Columnas calculadas · Funciones · Nombres de variables
Categorías · Fechas y periodos · Vectorización · Pipeline

Dudas del taller anterior

¿Qué problema te costó más resolver?

¿Qué regla aplicaste y con qué evidencia?

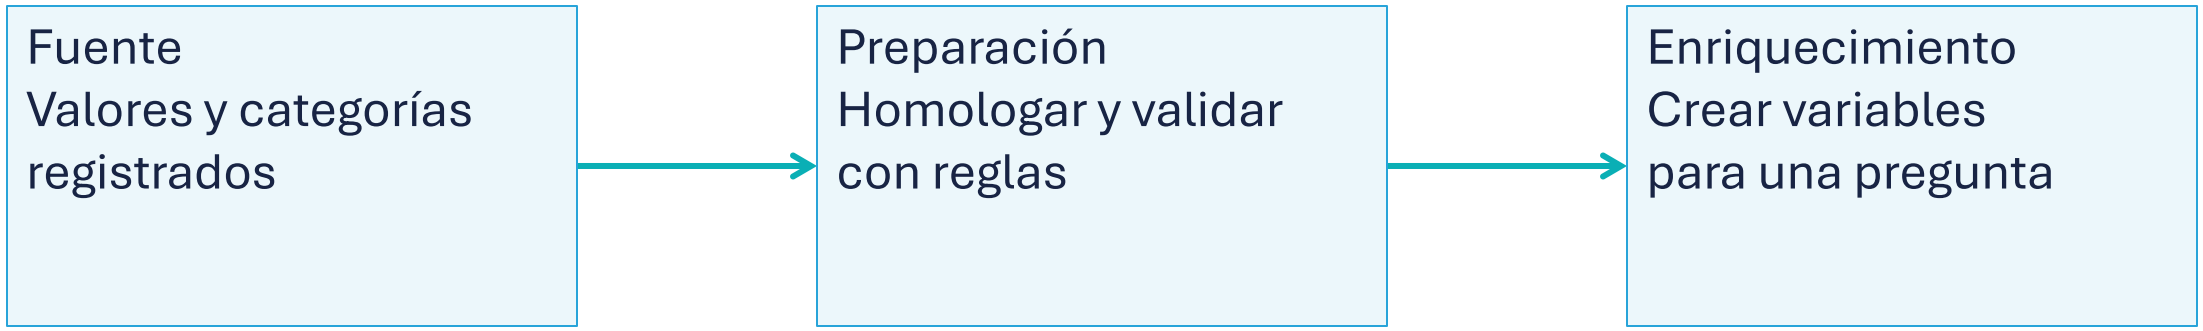
¿Cómo comprobaste el efecto de tus cambios?

Preparación esperada

Fuente	Separación controlada	Base preparada
123 registros	2 copias exactas adicionales	119 matrículas
12 columnas iniciales	2 filas con llave contradictoria	Llave de matrícula única

Conservamos valores fuente y banderas de revisión.
Los campos pendientes siguen siendo desconocidos.

Calidad y significado analítico



Una matrícula puede ser válida para un análisis y tener campos pendientes para otro.

Transformar y enriquecer

Acción	Ejemplo	Efecto
Homologar	Mercadeo = Marketing	Unificar categorías equivalentes
Renombrar	valor_matricula → valor_bruto_matricula	Explicitar el significado
Enriquecer	edad → rango_edad	Crear una variable analítica

Cada variable nueva necesita una definición y una regla.

Quiz 1 · ¿Qué acción crea una variable analítica?

A. Quitar espacios de la sede.

B. Crear un rango de edad.

C. Homologar Mercadeo como Marketing.

Responde con A, B o C por el chat o por el micrófono.

Quiz 1 · ¿Qué acción crea una variable analítica?

A. Quitar espacios de la sede.

B. Crear un rango de edad.

C. Homologar Mercadeo como Marketing.

Respuesta B. El rango añade una representación para segmentar matrículas.

Nombres que expliquen el dato

valor_matricula **valor_bruto_matricula**

```
analitica = analitica.rename(
   columns={'valor_matricula': 'valor_bruto_matricula'}
)
```

La etiqueta cambia. Los valores y la unidad COP se conservan.
La asignación conserva el DataFrame que devuelve rename().

Funciones sobre columnas

Herramienta	Uso	Ejemplo
.str	Operar sobre texto	Quitar espacios y normalizar mayúsculas
.map(diccionario)	Aplicar equivalencias conocidas	Mercadeo se homologa a Marketing
.apply(función)	Aplicar una función particular	Regla propia sin método directo

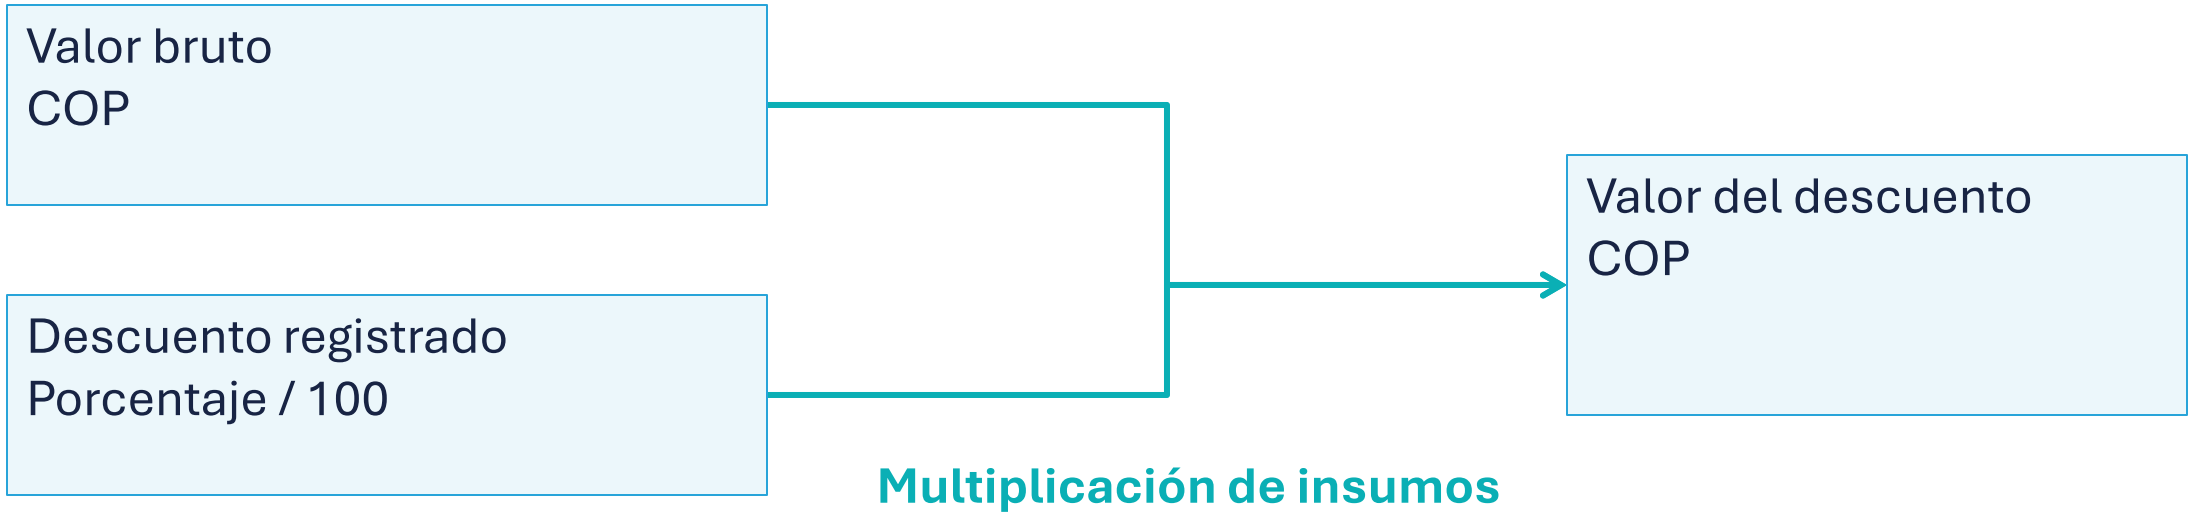
Primero revisamos si Pandas ofrece una operación directa.

Homologación con un mapa

```
mapa = {'mercadeo': 'Marketing', 'marketing': 'Marketing'}
clave = base['programa_fuente'].astype('string').str.strip().str.lower()
programa_homologado = clave.map(mapa)
```

Valor fuente	Clave normalizada	Resultado
Mercadeo	mercadeo	Marketing
MARKETING	marketing	Marketing
No registrado	no registrado	Desconocido

Columnas calculadas




```
analitica['valor_descuento'] = (
   analitica['valor_bruto_matricula'] * analitica['descuento_pct'] / 100
).round(2)
```

Vectorización

Matrícula	Valor bruto	Descuento %	Operación por fila
M0001	1.200.000	20	Columna bruto × columna porcentaje
M0002	1.400.000	0	La misma regla
M0003	1.800.000	0	La misma regla

Una expresión opera sobre las Series completas.
No necesitamos escribir un ciclo para cada matrícula.

Quiz 2 · ¿Qué describe una operación vectorizada?

A. Escribir un ciclo para cada matrícula.

B. Aplicar una expresión sobre columnas completas.

C. Convertir todas las columnas a texto.

Responde con A, B o C por el chat o por el micrófono.

Quiz 2 · ¿Qué describe una operación vectorizada?

A. Escribir un ciclo para cada matrícula.

B. Aplicar una expresión sobre columnas completas.

C. Convertir todas las columnas a texto.

Respuesta B. La operación entre Series expresa la misma regla para todas sus filas.

Valor neto e insumos pendientes

```
analitica['valor_neto_matricula'] = (
    analitica['valor_bruto_matricula'] - analitica['valor_descuento']
).round(2)
```

Situación	Resultado
Descuento conocido de 0 %	Se puede calcular el neto
Descuento desconocido	El neto queda desconocido
Valor neto calculado	No demuestra pago ni recaudo efectivo

Categorización de edades

Rango	Intervalo de Pandas	Etiqueta
16 a 24	[16, 25)	16–24
25 a 34	[25, 35)	25–34
35 a 44	[35, 45)	35–44
45 a 59	[45, 60)	45–59
60 a 80	[60, 81)	60–80

right=False incluye el límite izquierdo y excluye el derecho.
La edad pendiente recibe «Sin información».

pd.cut() y los límites

```
cortes = [16, 25, 35, 45, 60, 81]
etiquetas = ['16–24', '25–34', '35–44', '45–59', '60–80']
analitica['rango_edad'] = pd.cut(
    analitica['edad'], bins=cortes, labels=etiquetas, right=False
).astype('string').fillna('Sin información')
```

Edad de prueba	24	25	80	Desconocida
Categoría	16–24	25–34	60–80	Sin información

Quiz 3 · ¿Cómo categorizamos una edad desconocida?

A. Usamos el rango más frecuente.

B. Interpretamos el faltante como cero.

C. Asignamos Sin información.

Responde con A, B o C por el chat o por el micrófono.

Quiz 3 · ¿Cómo categorizamos una edad desconocida?

A. Usamos el rango más frecuente.

B. Interpretamos el faltante como cero.

C. Asignamos Sin información.

Respuesta C. La categoría reconoce que falta evidencia para asignar un rango de edad.

Fechas interpretables y fechas válidas

Caso	Python puede convertir	Regla del caso
2026-02-30	No: fecha imposible	Revisar
Matrícula después del inicio	Sí: ambas fechas existen	Revisar contradicción
Fecha de inicio faltante	No hay fecha conocida	Anticipación no evaluable

```
pd.to_datetime(columna, format='%Y-%m-%d', errors='coerce')
```

errors="coerce" identifica entradas no interpretables como NaT.

Días de anticipación




```
dias = (analitica['fecha_inicio'] - analitica['fecha_matricula']).dt.days
analitica['dias_anticipacion'] = dias.mask(analitica['revisar_fecha'])
```

La bandera de revisión evita usar plazos contradictorios.

Quiz 4 · ¿Qué necesitamos para calcular anticipación?

A. Dos fechas convertidas y consistentes con la regla.

B. Texto de fechas y cualquier valor negativo.

C. Solo el mes de inicio.

Responde con A, B o C por el chat o por el micrófono.

Quiz 4 · ¿Qué necesitamos para calcular anticipación?

A. Dos fechas convertidas y consistentes con la regla.

B. Texto de fechas y cualquier valor negativo.

C. Solo el mes de inicio.

Respuesta A. Convertir el formato es necesario; también debemos validar la relación entre fechas.

Mes y periodo académico

Variable	Ejemplo	Qué representa
fecha_matricula	2026-01-10	Un día registrado
mes_matricula	2026-01	Un intervalo mensual
periodo	2026-1	El periodo académico de la fuente

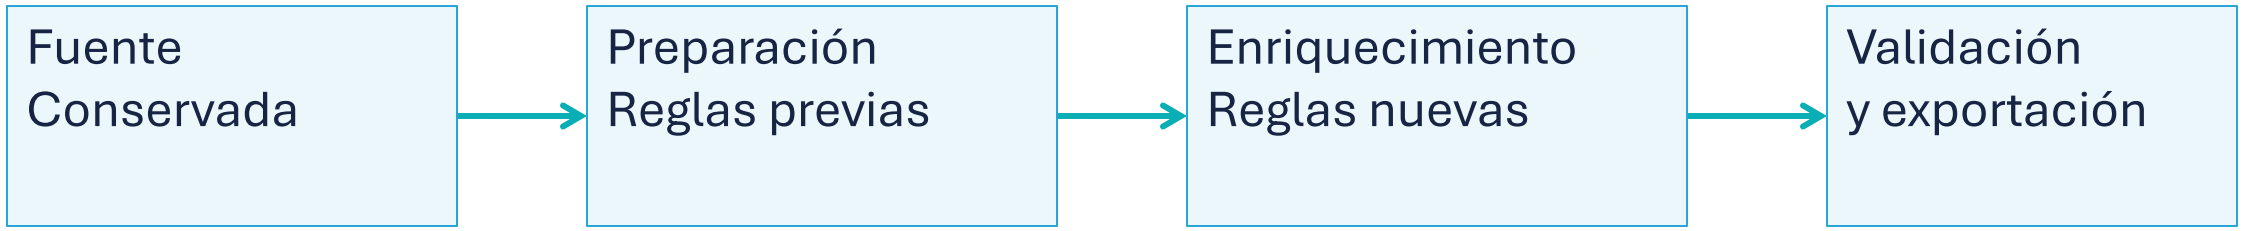
```
analitica['mes_matricula'] = analitica['fecha_matricula'].dt.to_period('M')
```

Reglas de anticipación

Condición	Categoría
Días conocidos ≥ 15	Anticipada
Días conocidos ≥ 0 y < 15	Cercana al inicio
Fechas pendientes de validación	No evaluable

```
analitica['tipo_anticipacion'] = 'No evaluable'
analitica.loc[analitica['dias_anticipacion'].ge(15),
        'tipo_anticipacion'] = 'Anticipada'
```

Pipeline reproducible



Misma entrada + mismas reglas = mismo resultado

Una función recibe la base y el umbral. Trabaja en una copia y devuelve la salida.

Quiz 5 · ¿Qué hace reproducible una preparación?

A. Corregir a mano el archivo exportado.

B. Ejecutar solo las celdas que recordamos.

C. Ejecutar desde la fuente con reglas explícitas y ordenadas.

Responde con A, B o C por el chat o por el micrófono.

Quiz 5 · ¿Qué hace reproducible una preparación?

A. Corregir a mano el archivo exportado.

B. Ejecutar solo las celdas que recordamos.

C. Ejecutar desde la fuente con reglas explícitas y ordenadas.

Respuesta C. La secuencia debe reconstruir el resultado sin depender de cambios manuales ocultos.

Pausa de 20 minutos

Regresamos a las 8:20 p. m.
Laboratorio de matrículas en Google Colab

Esumer
Educación Superior
VIGILADO MINEDUCACIÓN

Laboratorio de transformación

1. Conexión a Drive y preparación resuelta
2. Nombres y cálculos monetarios
3. Categorías de edad
4. Fechas, anticipación y mes
5. Segmento e interpretación
6. Función reproducible y exportación

40 minutos de trabajo. Consulta las pistas y las comprobaciones.

Apoyos para avanzar con autonomía

Si necesitas…	Apoyo en el notebook
Entender qué debes construir	Meta y regla del ejercicio
Recordar cómo escribirlo	Pista conceptual y ayuda desplegable
Comprobar si está bien	Casos de prueba y controles
Interpretar un error	Tabla de diagnóstico al final

Cada regla debe explicar límites, insumos y valores desconocidos.

Quiz 6 · ¿Cómo validamos una categorización?

A. Probamos límites y valores desconocidos.

B. Solo comprobamos que el código no tenga errores.

C. Rellenamos toda categoría pendiente con la más común.

Responde con A, B o C por el chat o por el micrófono.

Quiz 6 · ¿Cómo validamos una categorización?

A. Probamos límites y valores desconocidos.

B. Solo comprobamos que el código no tenga errores.

C. Rellenamos toda categoría pendiente con la más común.

Respuesta A. Los casos de frontera y los faltantes comprueban que la regla conserva su significado.

Cierre y avance del proyecto

La próxima clase usará estas variables para construir indicadores con groupby.

Encuesta después de la sesión · 3 minutos

Una respuesta por estudiante: modalidad de trabajo, integrantes, tema, datos y apoyo requerido.

Individual o equipos de máximo cuatro. Exposición de máximo diez minutos el 27 de noviembre.