Pandas: DataFrames y diagnóstico de calidad

Módulo 2 · Limpieza y Gestión de Datos

Estud-IA
HABILIDADES DIGITALES

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

Agenda del día

Bloque	Minutos
Módulo 2 y proyecto final	10
Repaso de Pandas y diagnóstico	30
Calidad, decisiones y conversación	30
Receso	20
Laboratorio y comparación de resultados	50
Cierre	10

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

Módulo 2: Construir

Limpieza y Gestión de Datos

Prepararemos datos para analizarlos con confianza.
Pandas será nuestra herramienta principal en Google Colab.

La ruta del módulo

Tema	Qué aprenderemos
Diagnóstico de calidad	Encontrar problemas y justificar tratamientos
Transformación	Crear variables y preparar formatos
Agrupaciones	Resumir por categorías con groupby
Integración de fuentes	Unir tablas y comprobar sus llaves
Visualización	Elegir gráficos y comunicar con claridad

Proyecto final

Individual o grupos de máximo 4

Caso aplicado a una pregunta relevante. No necesita incluir todo el curso.

27 de noviembre · Masterclass presencial

Exposición de máximo 10 minutos. Entrega: presentación con contexto y hallazgos.

Datos propios o públicos

No se requiere entregar la base. Protejan información personal y confidencial.

Contenido de la exposición

Parte sugerida	Pregunta guía
Contexto y pregunta	¿Qué problema o decisión abordaron?
Datos y preparación	¿Qué datos usaron y qué corrigieron?
Hallazgos con evidencia	¿Qué encontraron y cómo lo sustentan?
Conclusiones y límites	¿Qué recomiendan y qué no pueden afirmar?

Los mejores trabajos podrán presentarse en la semana de la innovación.

Ejemplos de proyectos

Caso	Pregunta posible
Matrículas	¿Cómo cambian por programa y periodo?
Ventas de un negocio	¿Qué productos concentran las ventas?
Encuesta de satisfacción	¿Qué aspectos requieren atención?
Gastos familiares	¿Cómo cambia el gasto por categoría?

Dónde encontrar datos

Página	Qué explorar
datos.gov.co	Datos publicados por entidades colombianas
dane.gov.co	Estadísticas y documentación de Colombia
medata.app.medellin.gov.co	Estadísticas y documentación de Medellín
data.worldbank.org	Indicadores por país y año
kaggle.com/datasets	Casos de educación, ventas y otros temas
archive.ics.uci.edu/datasets	Conjuntos documentados para análisis

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

Pandas:
DataFrames y diagnóstico de calidad

Nuestro caso de estudio hoy

Índice	Matrícula	Estudiante	Periodo
0	M0001	E001	2026-1
1	M0002	E002	2026-1
2	M0061	E001	2026-2

Matrícula: llave de este caso. Una fila representa una matrícula.
Estudiante: puede repetirse. Índice: posición o etiqueta de Pandas.

Series y DataFrames

Series

Una columna seleccionada como estructura de una dimensión.

DataFrame

Una tabla, incluso si conserva solamente una columna.

```
df['edad']

df[['edad']]

df[['programa', 'edad']]
```

Lectura de CSV y Excel

```
import pandas as pd

df = pd.read_csv('Matriculas_diagnostico.csv',
   encoding='utf-8-sig',
   dtype={'id_matricula': 'string'})

df = pd.read_excel('Matriculas_diagnostico.xlsx',
   sheet_name='Matriculas')
```

La lectura puede inferir tipos. Siempre revisamos el resultado.
CSV: separador y codificación. Excel: hoja de trabajo.

Selección de columnas y filas

Necesidad	Expresión
Varias columnas	df[['programa', 'edad']]
Primeras tres filas	df.iloc[0:3]
Fila con etiqueta 0	df.loc[0]
Filas filtradas y columnas	df.loc[condicion, ['programa', 'edad']]

La lógica de un filtro

Periodo	¿Igual a 2026-2?	¿Se conserva?
2026-1	False	No
2026-2	True	Sí
2026-1	False	No

```
condicion = df['periodo'].eq('2026-2')
df.loc[condicion, ['id_matricula', 'programa']]
```

Exploración inicial

Consulta	Qué nos dice
df.shape	Cantidad de filas y columnas
df.columns	Nombres de las variables
df.dtypes	Tipos que Pandas asignó
df.info()	Tipos y conteos no nulos
df.describe()	Resumen estadístico de columnas numéricas

Interpretación de describe

count

Cuenta valores conocidos, no necesariamente todas las filas.

mean, min, max y percentiles

Describen columnas numéricas. Ayudan a detectar valores que requieren revisión.

include="all"

Incluye otras variables. En texto aparecen categorías y frecuencias.

Dimensiones del diagnóstico

Dimensión	Pregunta
Completitud	¿Qué información falta y dónde?
Unicidad	¿La llave identifica una matrícula?
Validez	¿Los formatos y rangos son admisibles?
Consistencia	¿Las categorías y campos concuerdan?

Nulos visibles y faltantes ocultos

Nulos reconocidos

NaN, pd.NA o NaT, según el tipo de variable.

Faltantes ocultos

Espacios, “s/d” o códigos especiales definidos por la fuente.

```
df.isna().sum()

df.isna().mean() * 100

(df['edad'].astype('string')
   .str.strip())
```

Pregunta: falta la edad

¿Cuál sería el primer paso?

A Reemplazar por cero

B Eliminar todas las filas incompletas

C Usar la mediana automáticamente

D Revisar contexto y distribución de los faltantes

Pregunta: estudiante repetido

Un estudiante aparece en dos filas. ¿Qué hacemos?

A Borrar la segunda fila

B Borrar ambas filas

C Revisar las matrículas y la llave del caso

Duplicados exactos y de llave

```
df.duplicated().sum()

df.duplicated('id_matricula', keep=False)

df.drop_duplicates()
```

Copias exactas confirmadas: conservar una y registrar las descartadas.
Llaves contradictorias: separar las versiones para validación.

Tipos incorrectos y conversiones

```
edad = pd.to_numeric(df['edad'], errors='coerce')

fallos = df['edad'].notna() & edad.isna()
df.loc[fallos, ['id_matricula', 'edad']]

fecha = pd.to_datetime(df['fecha_matricula'],
    format='%Y-%m-%d', errors='coerce')
```

Una conversión que termina sin errores puede generar nuevos nulos.

Categorías y reglas de consistencia

Fuente	Tratamiento confirmado
analítica / ANALÍTICA	Analítica
Mercadeo	Marketing
Administracion	Administración
No registrado	Pendiente. No asignar al programa más frecuente

Rangos del caso: edad 16–80 y descuento 0–100.
Relación entre campos: matrícula anterior o igual al inicio.

Pregunta: un valor muy alto

Una matrícula cuesta mucho más que las demás.

A Eliminarla por ser atípica

B Validar programa, unidad y condiciones

C Reemplazarla por la media

Limpieza y sesgo

Los faltantes se concentran en la sede Virtual. ¿Qué cambia si eliminamos esas matrículas?

¿Quiénes dejan de aparecer?
¿Cambian los indicadores?
¿Podemos recuperar el dato o conservarlo como desconocido?

Decisiones de tratamiento

Decisión	Condición necesaria
Corregir	Formato o equivalencia confirmados
Imputar	Método justificado y efecto evaluado
Excluir	Criterio explícito y registro de lo excluido
Conservar y marcar	Evidencia insuficiente para resolver

Fuente original, copia de trabajo, bitácora y validación del resultado.

Receso: 20 minutos

Al regresar: notebook y archivo de matrículas
en Google Colab

Esumer
Educación Superior
VIGILADO MINEDUCACIÓN

Laboratorio: estudiantes y matrículas

123 registros · 12 variables · 2 periodos

Pregunta del caso

¿Podemos describir matrículas, edades y valores con esta información?

Producto del taller

Auditoría, reglas de tratamiento y comparación antes/después.

Archivos

Notebook de estudiantes + Matriculas_diagnostico.csv

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

Taller: auditoría guiada

1 Reconocimiento

Tamaño, columnas, tipos y significado de una fila.

2 Evidencias

Nulos, repeticiones, categorías y conversiones fallidas.

3 Decisiones

Problema, regla propuesta, evidencia e impacto esperado.

Taller: limpieza sobre una copia

Paso	Control
Separar copias y conflictos	Conciliar registros y conservar archivos separados
Normalizar categorías	Usar equivalencias confirmadas
Convertir números y fechas	Conservar valores fuente y marcar fallos
Revisar rangos y relaciones	No inventar valores para completar la tabla

Taller: antes y después

Control	Resultado de referencia
Registros conciliados	123 = 2 copias + 2 pendientes + 119 base
Llaves repetidas en la base	0
Edades desconocidas en la base	12, incluidas inválidas detectadas
Media de edad	Comparar edades conocidas vs. rellenar con cero

Más nulos pueden reflejar problemas antes ocultos.
La base preparada todavía tiene campos pendientes.

Cierre y siguiente clase

¿Qué corregiste?
¿Qué conservaste como desconocido?
¿Qué análisis todavía requiere validación?

Siguiente paso: transformación y enriquecimiento de datos.
Nuevas variables, formatos y un proceso reproducible.

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación
SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín
Esumer
Educación Superior