AGRUPACIONES Y ANÁLISIS CON GROUPBY

Indicadores por categorías y periodos

Análisis y Visualización de Datos para la Toma de Decisiones

Docente: Johan Steev Muriel Mosquera

Estud-IA
HABILIDADES DIGITALES

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

Objetivo de aprendizaje

Comprender cómo agrupaciones, agregaciones y denominadores modifican el significado de un indicador y evaluar comparaciones por categorías y periodos.

Bloque	Minutos	Bloque	Minutos
Inquietudes	30	Descanso	20
Indicador	10	Participaciones	20
groupby	20	Laboratorio	35
Agregaciones y práctica	15	Cierre	10

Limpieza: decisiones que preservan significado

Decisión	Qué preservamos
Identificadores como texto	Códigos y ceros iniciales
Separar copias exactas y llaves contradictorias	Diferencia entre repetición y conflicto
Homologar categorías y convertir valores	Comparaciones consistentes
Validar rangos	Valores que requieren revisión
Conservar faltantes y banderas	Información sobre calidad y cobertura

Un estudiante repetido no equivale a una matrícula duplicada.

Enriquecimiento: nuevas variables con reglas

Variables derivadas	Cuidado de interpretación
Valor bruto, descuento y neto	El neto calculado no es recaudo
Rangos de edad	Mantener la regla de clasificación
Días y tipo de anticipación	Contradicción: no evaluable
Mes de matrícula y semestre	Representan referencias temporales distintas

Una regla explícita permite explicar cada nueva variable.

Inquietudes de los laboratorios 7 y 8

23 minutos

No necesitas haber completado las prácticas para participar.

- Comparte por voz o chat:

- 1. La operación que intentaste
- 2. El error o resultado obtenido
- 3. Lo que esperabas obtener

- Revisaremos uno o dos ejemplos concretos.

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

Una fila y una pregunta

Cada fila es una matrícula. Un estudiante puede repetirse.
Universo del laboratorio: todos los estados.

id_matricula	id_estudiante	estado	rango_edad	neto (COP)
D1	E1	Activa	16–24	$ 100
D2	E1	Activa	16–24	$ 200
D3	E2	Finalizada	25–34	$ 300
D4	E3	Activa	25–34	$ 400
D5	E4	Cancelada	35–44	$ 500
D6	E5	Cancelada	35–44	

Demostración sintética: valores ilustrativos en COP, ajenos al CSV.

Quiz 1 · Personas y matrículas

Con la tabla anterior, queremos conocer personas atendidas en total.

A Sumar filas de todos los estados.

B Contar id_estudiante distintos en todo el universo y declarar los estados incluidos.

C Contar valores netos disponibles.

D Sumar personas de cada segmento siempre, sin revisar superposición.

Responde por voz o chat y explica tu elección.

Respuesta 1 · El conteo depende de la unidad

B **6 matrículas** **5 personas distintas**

La suma de personas por segmentos solo coincide cuando no existe superposición entre ellos.

En otros conjuntos, una misma persona puede estar en varios estados o programas.

Nombre del indicador = medida + unidad + universo

La lógica de groupby

1. Separar por estado

Entrada: estado	Matrículas trazables
Activa	D1, D2, D4
Finalizada	D3
Cancelada	D5, D6

2. Calcular

size
3
1
2

3. Reunir

estado	matrículas
Activa	3
Cancelada	2
Finalizada	1

D1–D6 aparecen una vez en la entrada. La salida tiene una fila por estado.

Primer resumen

demo.groupby("estado", dropna=False).size()

estado (índice)	Resultado
Activa	3
Cancelada	2
Finalizada	1

El índice identifica los grupos.

reset_index devuelve columnas para seguir trabajando.

.reset_index(name="matriculas")

Agrupación por varias categorías

```
(demo.groupby(["estado", "rango_edad"], dropna=False, observed=True)
    .size().reset_index(name="matriculas"))
```

estado	rango_edad	matriculas
Activa	16–24	2
Activa	25–34	1
Cancelada	35–44	2
Finalizada	25–34	1

Una fila de salida representa una combinación, no una matrícula.

Filas, valores disponibles y personas

Grupo	size Filas	count de neto Disponibles	nunique estudiante Personas
Activa	3	3	2
Cancelada	2	1	2

count exige elegir el campo: aquí contamos netos disponibles.

El desconocido de D6 no es cero.

Agregaciones múltiples con nombres claros

```
(demo.groupby("estado", dropna=False).agg(
   matriculas=("id_matricula", "size")          , personas=("id_estudiante", "nunique"),
   netos_disponibles=("neto", "count"),
   neto_conocido=("neto", lambda s: s.sum(min_count=1)),
   neto_promedio=("neto", "mean")).reset_index())
```

estado	matriculas	personas	netos disponibles	neto conocido	neto promedio
Activa	3	2	3	$ 700	$ 233,33
Cancelada	2	2	1	$ 500	$ 500,00
Finalizada	1	1	1	$ 300	$ 300,00

COP. min_count=1: un grupo sin netos no tiene suma conocida.

Quiz 2 · Un promedio con información incompleta

Programa 1: $ 1,2 millones de promedio neto y 100 % conocido.
Programa 2: $ 1,4 millones de promedio neto y 40 % conocido.

A El segundo recauda más.

B El segundo es más rentable.

C El promedio observado del segundo es mayor, pero falta revisar cobertura y comparabilidad.

D Los desconocidos valen cero y hay que incluirlos.

Responde por voz o chat y explica tu elección.

Respuesta 2 · Valor observado y cobertura

C El promedio usa valores disponibles.

Qué sí podemos decir	Qué falta revisar
Promedio observado del segundo mayor	Cobertura y comparabilidad
Cobertura desigual entre programas	Patrón de los faltantes

La tasa de faltantes no revela por sí sola la dirección del sesgo.

PRIMERA PRÁCTICA EN COLAB

- 1. Abre el notebook Clase 9.
- 2. Ejecuta montaje de Drive y carga.
- 3. Verifica 119 matrículas únicas.
- 4. Completa el ejercicio 1 por programa y periodo.

- Acompaña cada suma monetaria con la cantidad de netos disponibles.

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

Descanso
20 minutos

Vuelve con Colab abierto.

Deja identificado el paso en el que continuarás.

Ordenamiento y lectura del resumen

```
resumen.sort_values("matriculas", ascending=False)
```

estado	matriculas
Activa	3
Cancelada	2
Finalizada	1

Ordenar facilita leer.
El indicador conserva su significado.

Mayor volumen no implica mejor desempeño.

Categoría desconocida: conservar con dropna=False o etiquetar con transparencia.

Participación: un denominador explícito

Periodo	Norte	Sur	Total de matrículas	Participación Norte
A	40	60	100	40 %
B	45	105	150	30 %

Mini tabla sintética separada de la demostración D1–D6 y del CSV.

Todos los estados del universo contribuyen al denominador.
Participación de matrículas y de valor neto conocido miden cosas distintas.

Calcular dentro de cada periodo

```
resumen["total_periodo"] = (
   resumen.groupby("periodo")["matriculas"].transform("sum"))
resumen["participacion_pct"] = (
   resumen["matriculas"] / resumen["total_periodo"] * 100)
```

periodo	sede	matriculas	total_periodo	participacion_pct
A	Norte	40	100	40 %
A	Sur	60	100	60 %
B	Norte	45	150	30 %
B	Sur	105	150	70 %

transform repite el total en cada fila. Cada periodo suma 100 % antes de redondear.

Quiz 3 · Crecer y perder participación

Norte pasa de 40 a 45 matrículas. El total pasa de 100 a 150.

A Hay un error porque ambas cifras deben crecer juntas.

B Aumenta el volumen, pero su crecimiento es menor que el del total.

C Pierde estudiantes necesariamente.

D Tiene menos matrículas absolutas.

Responde por voz o chat y explica tu elección.

Respuesta 3 · Comparaciones diferentes

B

Medida	Cambio en Norte	Lectura
Volumen	+5 matrículas	Diferencia absoluta
Variación	+12,5 %	Cambio relativo al volumen inicial
Participación	40 % a 30 %	Peso dentro del total
Puntos porcentuales	−10 puntos	Diferencia entre participaciones

No equivale a pérdida de personas ni prueba una causa.

Comparación entre periodos

resumen.pivot(index="sede", columns="periodo", values="matriculas")

sede	A (base)	B (actual)
Norte	40	45
Sur	60	105

Variación = (actual − base) / base
Para porcentaje: multiplicar por 100.

Puntos porcentuales = participación actual − anterior

Base cero o desconocida: variación no evaluable.
Ausencia de fila: tratar como cero solo con cobertura completa confirmada.

LABORATORIO · INDICADORES Y HALLAZGOS

Termina los ejercicios 1–4.

Usa las ayudas desplegables y comprobaciones del notebook.

No copies cifras del ejemplo.

- Entregables

- Indicadores por programa y periodo
- Indicadores por sede y periodo
- Comparación de sedes y controles

- Tres hallazgos, una limitación y un dato adicional necesario

Quiz 4 · Un total que no reconcilia

La base tiene 119 matrículas y el resumen por programa suma 118.

A Aceptar porque una fila es insignificante.

B Revisar grupos faltantes y filtros antes de interpretar.

C Eliminar una fila de la base para cuadrar.

D Sumar estudiantes en lugar de matrículas.

Responde por voz o chat y explica tu elección.

Respuesta 4 · Revisar exclusiones

B

119 en la base
118 en el resumen

Revisar
dropna, filtros y universo

groupby puede omitir llaves faltantes cuando no se pide conservarlas.
En esta base hay una matrícula con programa desconocido.

Con las reglas previstas, el resumen debe sumar 119 matrículas.

Resultados del caso y límites

Periodo	Matrículas	Netos conocidos	Suma de neto conocido (COP)
2026-1	59	53	$ 71.515.000
2026-2	60	60	$ 78.480.000

Sede	2026-1	2026-2
Centro	20	20
Robledo	20	20
Virtual	19	20

Caso sintético de institución ficticia.

La diferencia monetaria exige revisar cobertura. No es recaudo.

SOCIALIZACIÓN Y SIGUIENTE PREGUNTA

Comparte por voz o chat.

Dos o tres hallazgos del grupo, con evidencia y limitación.

- Para cada hallazgo
- ¿Qué observaste?
- ¿Qué resultado lo respalda?
- ¿Qué no puedes concluir?

- Siguiente pregunta
- Para conocer municipio y área de formación hacen falta fuentes complementarias.

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación Postsecundaria de Medellín

Esumer
Educación Superior