Merge, concatenación e integración de fuentes

Integrar y comprobar el resultado

Estud-IA
HABILIDADES DIGITALES

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación Postsecundaria de Medellín

Esumer
Educación Superior

Objetivo y recorrido

Comprender cómo las llaves, las uniones y la cardinalidad afectan una integración.

Evaluar cobertura, unicidad y conservación de indicadores.

Bloque	Minutos	Bloque	Minutos
Apertura	10	Descanso	20
Concatenación	20	Integración	20
Llaves y uniones	25	Laboratorio	40
Cardinalidad	15	Cierre	10

160 minutos en total. Los quizzes están incluidos en cada bloque.

Indicadores que necesitan otras fuentes

119

matrículas preparadas
en la Clase 9

Ya disponible	Requiere otra fuente
Programa, sede y periodo	Municipio del estudiante
Una fila por matrícula	Área de formación

Clase independiente: paquete de Clase 10 con los dos periodos, el maestro de estudiantes y el catálogo de programas.

Qué representa una fila en cada fuente

Fuente	Una fila representa	Llave
Matrículas	Una matrícula	id_matricula
Estudiantes	Un estudiante	id_estudiante
Programas	Un programa	programa

Muchas matrículas pueden corresponder a un estudiante o a un programa.

Contrato: cada maestro debe tener una llave única.

Concatenación vertical

Entrada A

Matrícula	Est.	Periodo
L1	E1	2026-1
L2	E2	2026-1

Entrada B

Matrícula	Est.	Periodo
L3	E1	2026-2

Salida

Matrícula	Est.	Periodo
L1	E1	2026-1
L2	E2	2026-1
L3	E1	2026-2

```
pd.concat([a, b], ignore_index=True)
```

Mismas columnas, tipos y significado. E1 conserva sus dos matrículas.
ignore_index renumera el índice, no elimina duplicados.

Concatenación horizontal

A: canal

Índice	id_A	Canal
0	E1	Web
1	E2	Sede

B: contacto

Índice	id_B	Contacto
0	E2	SMS
1	E1	Correo

pd.concat([A, B], axis=1)

Índice	id_A	Canal	id_B	Contacto
0	E1	Web	E2	SMS
1	E2	Sede	E1	Correo

Salida: alinea por índice. En la fila 0, E1 queda junto a E2.

Quiz 1 · Dos tablas del mismo tamaño

A y B tienen dos filas, pero las personas están en distinto orden.

A. concat con axis=1 las integra por id automáticamente.

B. reset_index en ambas garantiza la correspondencia.

C. Hay que revisar el índice y alinear por identidad o usar merge con la llave.

D. Ordenar por cualquier columna basta.

Responde por voz o chat y explica tu criterio.

Respuesta 1
Identidad y posición

C

Igual cantidad de filas o índice numérico no implica la misma persona.

La identidad debe guiar la correspondencia.

Salida correcta por identidad

Estudiante	Canal	Contacto
E1	Web	Correo
E2	Sede	SMS

Para concat horizontal: ambas tablas con una llave única y comprobada como índice.

Con merge: declarar la llave de forma explícita.

Llaves de integración

Una llave identifica la correspondencia entre fuentes.

Cuidado	Criterio
Ceros iniciales	Conservar la llave como texto
Espacios exteriores	Quitar espacios sin cambiar el significado
Tipos distintos	Usar tipos consistentes en ambas fuentes
Nombre de persona	Evitarlo como llave de integración

Ejemplo de llave compuesta

id_estudiante + periodo

Una fuente guarda un estado por semestre.

id_estudiante solo resulta insuficiente.

Esta fuente de estados semestrales no se ejecuta en el laboratorio principal.

Tipos de unión · Tabla de referencia

Izquierda: matrículas (m = matrículas)

id_matricula	id_estudiante
L1	E1
L2	E2
L3	E3

Derecha: estudiantes (e = estudiantes)

id_estudiante	Municipio
E1	Bello
E2	Medellín
E4	Envigado

Llave del cruce: id_estudiante. La derecha tiene llaves únicas.

Left e inner

Left: conserva la izquierda

Matrícula	Est.	Municipio
L1	E1	Bello
L2	E2	Medellín
L3	E3	Desconocido

```
m.merge(e, on="id_estudiante",
    how="left")
```

Inner: conserva coincidencias

Matrícula	Est.	Municipio
L1	E1	Bello
L2	E2	Medellín

```
m.merge(e, on="id_estudiante",
    how="inner")
```

La elección depende de la pregunta y del universo.

Right y outer

Right: conserva la derecha

Matrícula	Est.	Municipio
L1	E1	Bello
L2	E2	Medellín
Sin matrícula	E4	Envigado

how="right"

Outer: conserva ambas fuentes

Matrícula	Est.	Municipio
L1	E1	Bello
L2	E2	Medellín
L3	E3	Sin municipio
Sin matrícula	E4	Envigado

how="outer"

Diagnóstico de registros sin pareja y catálogos sin uso. E4 no es una matrícula.

Quiz 2 · Conservar el universo

Necesitamos enriquecer las matrículas sin excluir las que carecen de maestro.

A. Inner.

B. Left desde matrículas.

C. Right desde matrículas.

D. Concat vertical.

Responde por voz o chat y explica tu criterio.

Respuesta 2
Fuente y propósito

B

Matrículas es la izquierda y determina el universo.

Los faltantes se identifican y se reportan.

Left conserva las matrículas sin pareja.

Pero left, por sí solo, no garantiza el mismo número de filas.

La cardinalidad también importa.

Cardinalidad

Relación	Filas de izquierda	Filas de derecha	Combinaciones
Uno a uno	L1/E1	E1/Bello	L1 con Bello
Muchos a uno	L1/E1, L2/E1	E1/Bello	L1 y L2 con Bello
Muchos a muchos	L1/E1, L2/E1	E1/Bello, E1/Medellín	L1/Bello, L1/Medellín L2/Bello, L2/Medellín

Laboratorio: muchos a uno desde matrículas hacia cada maestro.

Uno a muchos puede cambiar legítimamente la unidad, pero aquí no se permite.

Una unión que multiplica cifras

Entradas

Matrícula	Est.	Neto COP
L1	E1	$100
L2	E1	$200

Est.	Municipio
E1	Bello
E1	Medellín

$300

Salida incorrecta para el contrato

Matrícula	Municipio	Neto COP
L1	Bello	$100
L1	Medellín	$100
L2	Bello	$200
L2	Medellín	$200

$600

Conflicto del maestro: no elegir una versión al azar ni borrar matrículas después.

Quiz 3 · Neto duplicado

Después de unir, se duplican las filas y la suma monetaria.

A. Es crecimiento de la institución.

B. Revisar llaves repetidas del maestro y la cardinalidad esperada.

C. Dividir siempre los valores por dos.

D. Ignorar filas duplicadas porque merge funcionó.

Responde por voz o chat y explica tu criterio.

Respuesta 3
El cruce también cambia cantidades

B

Cada coincidencia genera una combinación.

El contrato esperaba muchos a uno.

2 filas de E1 × 2 versiones de E1
= 4 combinaciones

El ejemplo es muchos a muchos.

La revisión debe ocurrir antes de agregar: sumar después oculta la multiplicación.

Controles antes de integrar

Estructura	Calidad de llaves	Referencia
Unidad de registro	Nulos y espacios exteriores	Conteo de filas
Relación esperada	Tipos consistentes y unicidad	Matrículas únicas
Una fila por matrícula	Copias exactas vs. contradicciones	Netos antes del cruce

Pandas puede emparejar llaves nulas.

Excluir llaves vacías de maestros. No convertirlas en un valor común.

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

Descanso

20 minutos

Al volver: archivos de Clase 10 en Drive y Google Colab abierto.

Un merge con contrato

```
resultado = matriculas.merge(
    estudiantes, on="id_estudiante", how="left",
    validate="many_to_one",
    indicator="cruce_estudiante"
)
```

Entrada: minitablas de referencia.
Salida esperada: L1, L2 y L3.
L3 queda pendiente.

Parámetro	Qué declara
on	Llave de correspondencia
how	Universo de matrículas
validate	Unicidad de la derecha
indicator	Estado de cada cruce

MergeError invita a revisar.

La validación no garantiza cobertura ni una llave correcta.

Registros emparejados y pendientes

Indicador	Significado	En un left
both	Llave presente en ambas fuentes	Sí
left_only	Llave solo en la izquierda	Sí
right_only	Llave solo en la derecha	No

Un municipio nulo no demuestra falta de emparejamiento.

Usar el indicador. Para catálogos sin uso: auditoría separada con outer y llaves distintas.

Primera integración en Colab

```
from google.colab import drive
drive.mount("/content/drive")
```

Ejercicio	Inicio concreto
1	Cargar dos periodos, maestro y catálogo desde Drive.
2	Quitar espacios exteriores y separar llaves vacías.
3	Eliminar solo la copia exacta y apartar todas las versiones contradictorias.

Comienza los ejercicios 1–3. Continúan en el bloque práctico.

Laboratorio · Integración independiente

Entregable: una fila por matrícula y pendientes explicados.

Municipio, situación laboral y área de formación.

Las demostraciones usan minitablas diferentes.

1. Concatenar los periodos y depurar el maestro.
2. Unir estudiantes y programas con contrato.
3. Diagnosticar matrículas sin pareja.
4. Resolver el ejercicio horizontal por identidad.
5. Comparar controles antes y después.
6. Exportar base integrada y pendientes.

Controles después de integrar

Nivel	Evidencia antes / después
Por periodo	Filas y matrículas únicas
Por periodo	Cantidad de netos disponibles y suma monetaria
Por id_matricula	Comparación de cada valor neto
Por cruce	Emparejadas / total de matrículas
Por muestra	Correspondencias entre identidad y atributos

La salida principal conserva una fila por matrícula.

Quiz 4 · Misma cantidad, ¿resultado correcto?

Una unión conserva 119 filas. ¿Qué podemos concluir?

A. Eso prueba calidad completa.

B. Eso prueba cobertura del 100 %.

C. También hay que revisar correspondencias, indicadores, unicidad y valores.

D. Ya no necesita validar llaves.

Responde por voz o chat y explica tu criterio.

Respuesta 4
Evidencia complementaria

C

Mantener 119 filas no garantiza correspondencias correctas.

Cada control aporta evidencia distinta.

Mismo conteo

Puede coexistir con una llave errónea, muchos pendientes o atributos alterados.

Incluso una suma igual puede ocultar cambios en valores individuales.

Resultados verificados del laboratorio

Cruce (119 matrículas)	Emparejadas	Pendientes	Cobertura
Estudiantes	113	6	94,96 %
Programas	117	2	98,32 %

Maestro: 1 llave vacía, 1 copia exacta y 2 versiones contradictorias.
E003 se separa. E059 y E060 están ausentes.

Especialización fuera de catálogo y un programa desconocido.
Diseño figura en el catálogo sin uso.

Netos por periodo	Antes	Después
2026-1	$71.515.000 COP	$71.515.000 COP
2026-2	$78.480.000 COP	$78.480.000 COP

Socialización y paso a visualización

10 minutos

¿Qué unión elegiste y qué universo conservaste?

¿Qué pendiente requiere consultar a la fuente?

¿Qué limitación debe acompañar el análisis de municipios?

Un tablero hereda los errores de integración.