Masterclass de repaso
Módulo 2 · Limpieza y gestión de datos

Clase 11 · Análisis y Visualización de Datos

Johan Steev Muriel Mosquera

Estud-IA
HABILIDADES DIGITALES

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

Objetivo del módulo y recorrido de la sesión

- Módulo 2: preparar datos confiables con Pandas para analizarlos.
- Hoy: relacionar diagnóstico, transformación, integración y análisis agregado.
- Meta: justificar cada decisión y comprobar sus efectos antes de interpretar resultados.

150 minutos en total

45 min Repaso teórico + 4 quizzes

20 min Intermedio

85 min Dudas y laboratorios

En virtual: responde por el chat. Cada etapa incluye quiz, respuesta y repaso teórico breve.

Una ruta de trabajo con datos

Cada etapa deja controles para la siguiente.

1

Diagnosticar

Entender estructura, tipos, faltantes y consistencia.

2

Transformar

Aplicar reglas explícitas y crear variables analíticas.

3

Integrar

Relacionar fuentes con llaves y cardinalidad esperada.

4

Resumir

Agrupar, calcular indicadores y leerlos con contexto.

Las validaciones ocurren antes y después de transformar o integrar.

QUIZ 1

¿Qué describe mejor un diagnóstico inicial de calidad?

- A. Revisar estructura, tipos, faltantes, duplicados y consistencia antes de decidir cambios.
- B. Eliminar todas las filas con algún valor faltante.
- C. Convertir todas las columnas a texto para evitar errores.
- *Escribe la letra de tu respuesta en el chat. Luego explica brevemente tu elección.*

RESPUESTA 1

A · Revisar antes de corregir.

- **¿Por qué?**
- El diagnóstico identifica señales de calidad; la decisión de corregir depende del significado del dato y de la pregunta analítica.
- *Ahora revisamos la idea teórica detrás de esta respuesta.*

1 · Diagnóstico de calidad

- Un DataFrame organiza observaciones en filas y variables en columnas; cada columna se representa como una Series.
- shape, columns, dtypes, info() y describe() permiten revisar tamaño, estructura, tipos y distribuciones.
- isna() y duplicated() ayudan a localizar faltantes y repeticiones. Esas señales se interpretan según la unidad de análisis.
- La limpieza aplica reglas justificadas y conserva trazabilidad de los cambios.

Primero definimos qué representa cada fila y qué significa cada variable.

QUIZ 2

¿Qué hace que una transformación sea confiable y reproducible?

- A. Aplicar una regla explícita, tratar los casos desconocidos y poder repetirla desde la fuente.
- B. Corregir manualmente solo el archivo final.
- C. Reemplazar los valores faltantes por cero en todas las variables.
- *Escribe la letra de tu respuesta en el chat. Luego explica brevemente tu elección.*

RESPUESTA 2

A · Aplicar reglas explícitas y repetibles.

- **¿Por qué?**
- Una transformación es confiable cuando sus criterios quedan claros y puede reconstruirse desde los datos de origen.
- *Ahora revisamos la idea teórica detrás de esta respuesta.*

2 · Transformación y enriquecimiento

- Transformar cambia la forma de representar una variable; enriquecer crea atributos nuevos para responder preguntas analíticas.
- La vectorización aplica operaciones sobre Series completas, con una misma regla para todos los registros.
- Las categorías, fechas y variables derivadas requieren reglas para límites, valores inválidos y datos desconocidos.
- Un pipeline ordena los pasos para repetir el proceso con la misma fuente y los mismos parámetros.

Una variable nueva necesita definición, regla y validación.

QUIZ 3

Necesitamos añadir atributos de una segunda tabla y conservar todas las filas de la tabla principal. ¿Qué conviene revisar y usar?

- A. Un merge left por una llave de negocio, comprobando unicidad y cardinalidad.
- B. Un concat horizontal porque ambas tablas tienen el mismo número de filas.
- C. Un merge inner para evitar valores faltantes.
- D. Un concat vertical, aunque las columnas tengan significados distintos.
- *Escribe la letra de tu respuesta en el chat. Luego explica brevemente tu elección.*

RESPUESTA 3

A · merge left por llave y con cardinalidad validada.

- **¿Por qué?**
- La llave establece qué registros corresponden; left conserva las filas de la fuente principal y la validación reduce el riesgo de multiplicaciones inesperadas.
- *Ahora revisamos la idea teórica detrás de esta respuesta.*

3 · Integración de fuentes

- concat(axis=0) apila observaciones con columnas compatibles; concat(axis=1) alinea por índice.
- merge empareja registros mediante una o más llaves. El tipo de unión define qué universo de filas se conserva.
- La cardinalidad describe cuántas filas pueden corresponder entre sí. Llaves repetidas pueden multiplicar registros.
- Revisar unicidad, faltantes, registros sin pareja y conteos antes y después ayuda a evaluar el resultado.

Primero fijamos la llave, el universo que se conserva y la cardinalidad esperada.

QUIZ 4

Al calcular la participación de cada categoría, ¿qué decisión hace interpretable el resultado?

- A. Definir qué se cuenta y cuál es el total de referencia para el porcentaje.
- B. Agrupar y ordenar de mayor a menor, sin revisar el denominador.
- C. Promediar todas las columnas numéricas y usar ese valor como participación.
- *Escribe la letra de tu respuesta en el chat. Luego explica brevemente tu elección.*

RESPUESTA 4

A · Definir el conteo y su denominador.

- **¿Por qué?**
- Una participación solo se interpreta al conocer qué población representa el total de referencia.
- *Ahora revisamos la idea teórica detrás de esta respuesta.*

4 · Agrupaciones y análisis con groupby

- groupby divide los registros en grupos según una o más variables y luego aplica funciones de agregación.
- sum, count, nunique y mean responden preguntas distintas; la elección depende de la unidad de análisis y del indicador.
- Los porcentajes comparan una parte con un total explícito. En comparaciones temporales, los periodos deben ser comparables.
- Una tabla agregada describe patrones observados; para afirmar causas se necesita evidencia adicional.

La agregación resume; la interpretación explica qué universo y qué medida resume.

Síntesis: controles que protegen el análisis

Antes de resumir

- ¿Qué representa una fila y qué población cubre?
- ¿Las reglas de limpieza y transformación son explícitas?
- ¿Las llaves y la cardinalidad coinciden con el propósito del cruce?

Antes de interpretar

- ¿Se conservaron las cantidades esperadas?
- ¿Qué grupos o registros quedaron fuera?
- ¿El porcentaje usa el denominador adecuado? ¿Qué conclusión sí permiten los datos?

Después del intermedio: clínica de laboratorios

85 minutos para resolver dudas y reconstruir decisiones clave.

5 min	**Recolectar dudas y priorizar**	Chat: comparte el laboratorio, celda y resultado esperado.
15 min	**Calidad y diagnóstico**	Tipos, nulos, duplicados, reglas y validaciones.
15 min	**Transformación**	Variables, categorías, fechas y pipeline reproducible.
15 min	**groupby**	Agregaciones, porcentajes y lectura de tablas resumen.
20 min	**Merge y concatenación**	Llaves, cobertura, cardinalidad y controles antes/después.
15 min	**Cierre integrador**	Una ruta de trabajo y una alerta de calidad para recordar.

Recursos abiertos en español

REDA Pascual Bravo · Trabajando con Pandas

Recurso interactivo abierto en español para afianzar el uso de Pandas. Requiere H5P.

Ciencia de Datos con Python · curso y ejercicios en Colab

Incluye sección de Pandas y cuadernos de ejercicios de Pandas para ejecutar en Google Colab.

EvoAcademy · Pandas en Python y Google Colab

Video gratuito en español con DataFrames, selección, estadísticos, filtros, valores faltantes y exportación; describe notebooks complementarios.

Sugerencia: empieza por un recurso guiado y practica después con una base propia.

Más práctica y documentación

Kaggle Learn · Pandas

Microcurso gratuito con ejercicios interactivos sobre lectura, selección, agrupación, tipos, faltantes y combinación de datos. Está en inglés.

Pandas · tutoriales de inicio

Tutoriales para DataFrames, lectura de archivos, selección y primeros análisis. La documentación oficial está en inglés.

Pandas · guías por tema

Consulta las guías oficiales de datos faltantes, groupby y merge/concat cuando necesites profundizar en una operación.

Las páginas enlazadas se consultaron el 16 de octubre de 2026.