FUNDAMENTOS DE ESTADÍSTICA DESCRIPTIVA

De los datos a una decisión: describir, resumir e interpretar.

Analítica y Visualización de Datos para la Toma de Decisiones

ESUMER

Estud-IA
HABILIDADES DIGITALES

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

Una pregunta antes de empezar

¿Cuánto compra normalmente un cliente?

$85.000 · $90.000 · $95.000 · $100.000 · $105.000 · $1.200.000

Primera intuición

¿Qué número usarías para representar a este grupo? ¿Qué información estás ignorando?

¿Qué vamos a aprender?

01

Reconocer variables y diferenciar población y muestra.

02

Resumir datos mediante frecuencias y medidas de tendencia central.

03

Medir dispersión y leer percentiles y distribuciones.

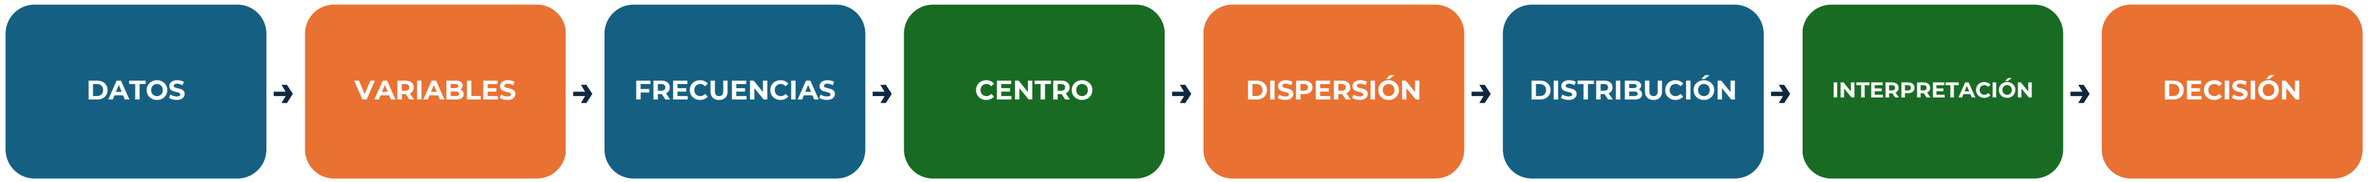
04

Interpretar indicadores sin afirmar más de lo que los datos permiten.

05

Aplicar todo sobre un mismo caso de negocio.

El mapa de la clase



La pregunta que conecta todo:

¿Qué podemos aprender de un conjunto de datos antes de tomar una decisión?

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

01 ¿Qué estamos midiendo?

Del dato aislado a una lectura útil para decidir.

Describir no es lo mismo que inferir

ESTADÍSTICA DESCRIPTIVA

Organiza, resume y describe los datos que tenemos.

ESTADÍSTICA INFERENCIAL

Usa una muestra para hacer afirmaciones sobre una población, bajo supuestos y métodos estadísticos.

Hoy nos concentraremos en describir bien antes de intentar inferir.

Población y muestra

1.000

clientes en la población

→

30

clientes en nuestra muestra

Pregunta clave

¿La muestra representa adecuadamente la población que queremos comprender?

Una muestra permite trabajar con una parte del universo; su utilidad depende de cómo fue seleccionada y del tamaño disponible.

¿Qué es una variable?

Una fila representa una unidad de análisis

CLIENTE

Una columna representa una característica observada

EDAD · CIUDAD · CANAL · COMPRA · SATISFACCIÓN

La variable es la característica que cambia de una unidad a otra.

Tipos de variables

CUALITATIVAS

Describen categorías o cualidades.

- Nominales: sin orden
- Ordinales: con orden

CUANTITATIVAS

Representan cantidades numéricas.

- Discretas: conteos
- Continuas: mediciones

Ejemplos del caso: ciudad → nominal | satisfacción → ordinal | compras → discreta | valor de compra → continua

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación
SAPIENCIA
Agencia de Educación Postsecundaria de Medellín
Esumer
Educación Superior

No todo número es una variable cuantitativa

ID cliente = 10234 ≠ **una cantidad que tenga sentido promediar**

Regla práctica

Antes de calcular, pregunta: ¿qué significa este número? ¿Es una medida, un conteo o solo una etiqueta?

Reto 1 · Conozcamos a nuestros clientes

En grupos • 10–12 minutos

- Identifiquen la unidad de análisis.
- Definan población y muestra.
- Clasifiquen las variables del diccionario.
- Elijan 3 variables útiles para una pregunta de negocio.
- Escriban esa pregunta sin intentar responderla todavía.

Producto

Una pregunta de negocio + las variables que necesitarían para responderla.

PISTA → Piensen como analistas, no como calculadoras.

Puesta en común · Reto 1

Una buena pregunta

Es específica, tiene una unidad de análisis clara y puede responderse con las variables disponibles.

Ejemplo

¿Los clientes recurrentes presentan un valor de compra mayor que los clientes nuevos?

Todavía no respondemos. Primero necesitamos aprender a resumir los datos.

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

02 ¿Cómo se distribuyen los datos?

Del dato aislado a una lectura útil para decidir.

De datos individuales a patrones

Redes sociales · Google · Redes sociales · Referidos · Google · Google · Google · …

Pregunta: ¿Qué canal aparece con mayor frecuencia?

La frecuencia convierte una lista de observaciones en una estructura que podemos comparar.

Frecuencia absoluta

Canal	Clientes
Redes sociales	11
Google	7
Referidos	6
Email	4

Frecuencia absoluta = número de veces que aparece una categoría.

Frecuencia relativa

10

clientes

→

33,3%

de la muestra

Frecuencia relativa = frecuencia / total

Pasamos de contar personas a expresar el peso de cada categoría dentro de la muestra.

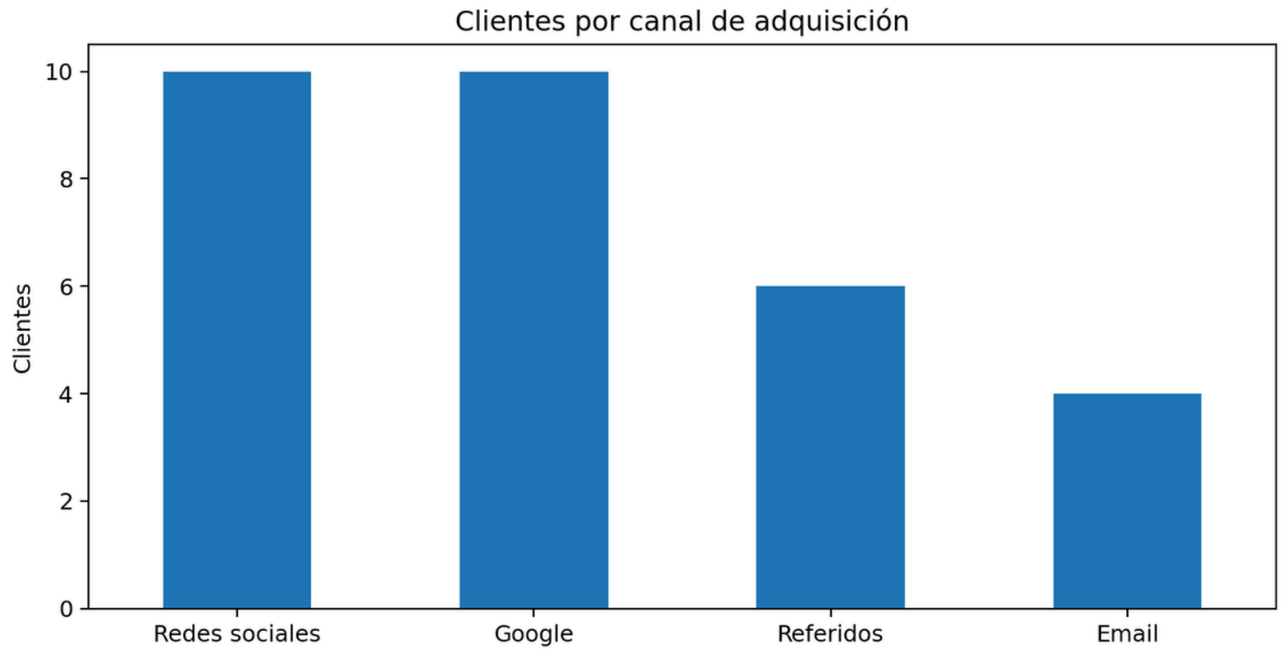
Frecuencia acumulada

Sirve cuando las categorías tienen un orden o cuando agrupamos valores.

Días de entrega	Clientes	Acumulado
1–2	11	11
3–4	13	24
5–6	6	30

Ejemplo: 24 de 30 clientes recibieron su pedido en 4 días o menos.

Una tabla también cuenta una historia



Primera lectura

En la muestra, Redes sociales y Google son los canales con más clientes.

Pero cuidado

Mayor frecuencia ≠ mayor efectividad.

Reto 2 · ¿De dónde vienen nuestros clientes?

En grupos • 10–12 minutos

- Construyan la tabla de frecuencias del canal de adquisición.
- Calculen la frecuencia relativa de cada canal.
- Identifiquen el canal o canales predominantes.
- Escriban una conclusión que sí pueden hacer.
- Escriban una conclusión que todavía NO pueden hacer.

Pregunta final

¿Podemos afirmar que el canal predominante es el más efectivo?

Puesta en común · Reto 2

Sí podemos decir

En nuestra muestra, Redes sociales y Google concentran 10 clientes cada uno (33,3%).

Todavía no podemos decir

Que esos canales generen más ventas, mayor rentabilidad o mejor conversión.

La frecuencia describe composición. La efectividad exige otros indicadores.

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

03 ¿Cuál es el comportamiento típico?

Del dato aislado a una lectura útil para decidir.

Tres formas de hablar de “lo típico”

MEDIA

El promedio: suma de los valores dividida por el número de observaciones.

MEDIANA

El valor que queda en el centro cuando ordenamos los datos.

MODA

El valor o categoría que más se repite.

Media · repartir el total por igual

Si juntáramos todo el dinero y lo repartiéramos por igual entre los clientes...

ese valor sería la media.

$$\bar{x} = \Sigma x_i / n$$

Pregunta analítica

¿El promedio representa bien al grupo cuando existen valores muy altos o muy bajos?

Mediana · encontrar el centro

Ordenemos los datos:

75	85	90	**95**	100	105	120

MEDIANA = 95

La posición importa más que la distancia entre los valores.

Moda · lo que más se repite

90.000 · 120.000 · 90.000 · 180.000 · 210.000 · 90.000

MODA = $90.000

La moda también puede ser una categoría: **“Redes sociales”**

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

¿Media o mediana? El efecto de un valor extremo

SIN EXTREMO

85 · 90 · 95 · 100 · 105

Media = 95
Mediana = 95

CON EXTREMO

85 · 90 · 95 · 100 · 1.200

Media = 314
Mediana = 95

La mediana permanece en el centro; la media se desplaza hacia el valor extremo.

Reto 3 · ¿Cuánto compra normalmente un cliente?

En grupos • 10–12 minutos

- Calculen media, mediana y moda del valor de última compra.
- Comparen los tres resultados.
- Identifiquen si un valor extremo está afectando la media.
- Decidan qué medida comunicarían como “compra típica” y por qué.

Dato clave

El dataset contiene una compra de $1.200.000.

Decisión

No basta con calcular: deben justificar la medida elegida.

Puesta en común · Reto 3

$217.833

media

$182.500

mediana

$90.000

moda

Una buena lectura: la media está elevada por una compra excepcionalmente alta.

Para “lo típico”, la mediana ofrece una representación más resistente al extremo.

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

04 ¿Qué tan diferentes son los clientes?

Del dato aislado a una lectura útil para decidir.

El promedio no cuenta toda la historia

GRUPO A

95 · 98 · 100 · 102 · 105

Media = 100

GRUPO B

60 · 80 · 100 · 120 · 140

Media = 100

Mismo promedio ≠ mismo comportamiento

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

Rango · la extensión más sencilla

RANGO = máximo − mínimo

En nuestro caso:

$1.200.000 − $70.000 = $1.130.000

Lectura

La muestra tiene una amplitud muy grande en los valores de compra.

Varianza · medir cuánto se alejan los datos

Idea intuitiva

¿Qué tan lejos están los datos del promedio?

La varianza resume las desviaciones respecto a la media elevándolas al cuadrado.

$$Var(X) = E(X^2) - [E(X)]^2$$

Más que memorizar la fórmula, interesa entender qué significa: variabilidad.

Desviación estándar · volver a las unidades originales

Varianza → unidades al cuadrado

Desviación estándar → unidades originales

Ejemplo de lectura:

Compra promedio = $180.000 **Desviación estándar = $40.000**

Interpretación: hay una variabilidad del orden de $40.000 alrededor del promedio.

Percentiles · ubicar una observación dentro de la distribución

P25

25% de los datos

P50

50% de los datos

P75

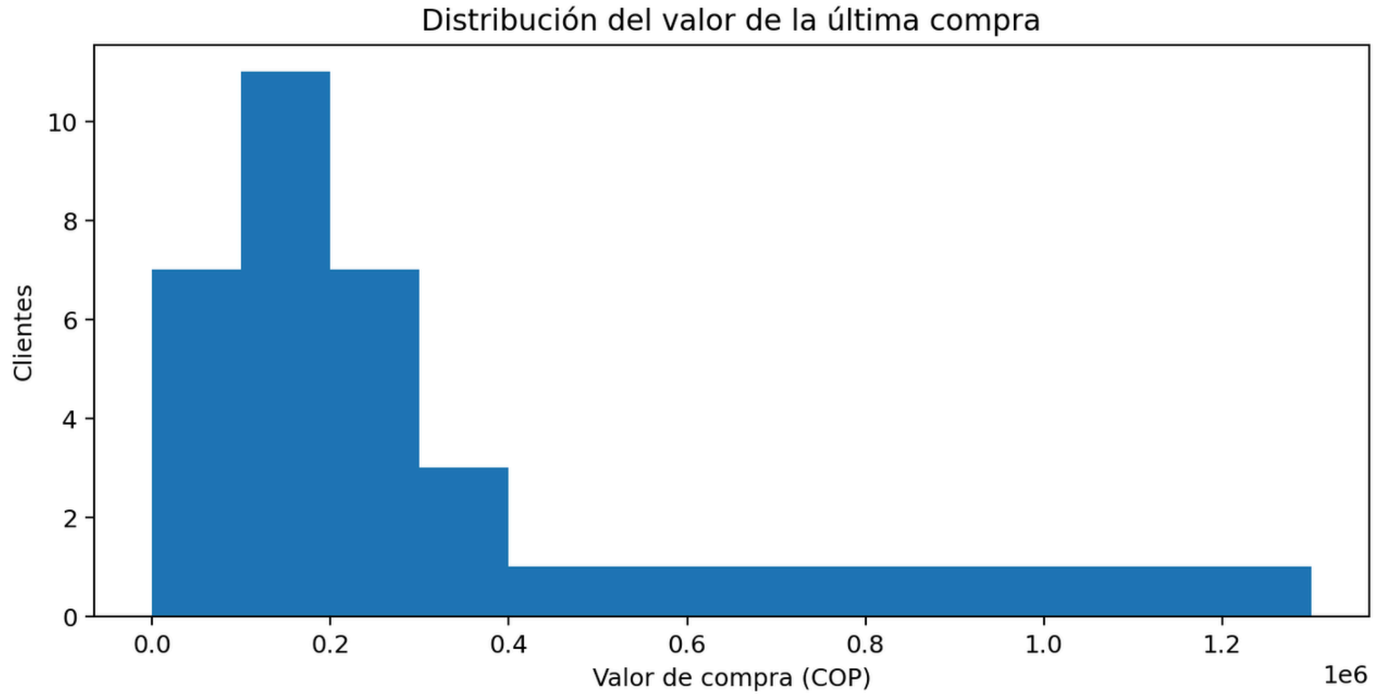
75% de los datos

En nuestro caso: P25 ≈ $101.250 · P50 = $182.500 · P75 ≈ $257.500

Interpretación correcta

P75 ≈ $257.500 significa que aproximadamente 75% de la muestra tiene un valor igual o inferior a ese monto.

Leer una distribución



Preguntas de lectura

¿Dónde se concentran los datos?
¿Hay una cola?
¿Hacia qué lado?
¿Hay valores alejados del patrón?

Simetría y asimetría

SIMÉTRICA

Los dos lados tienen una forma aproximadamente equilibrada.

SESGO A LA DERECHA

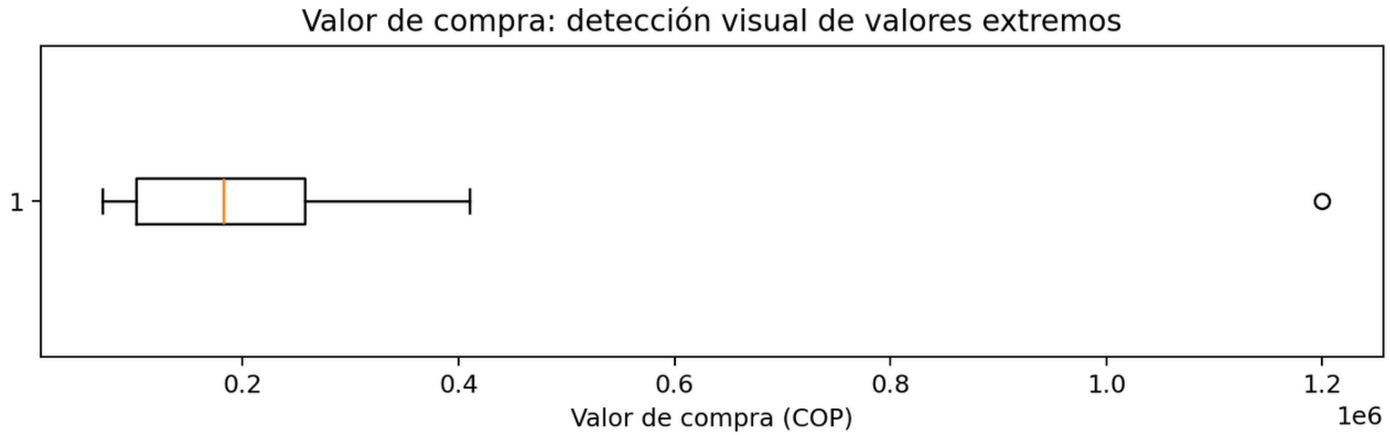
La cola se extiende hacia valores altos. La media suele quedar por encima de la mediana.

SESGO A LA IZQUIERDA

La cola se extiende hacia valores bajos. La media suele quedar por debajo de la mediana.

En el caso de compras, esperamos una distribución sesgada a la derecha.

Valores atípicos · atípico no significa incorrecto



Puede ser...

- un error de registro
- un caso excepcional
- un cliente real de alto valor
- una observación legítima que merece investigación

Primero detectar → después investigar → nunca eliminar automáticamente.

Reto 4 · ¿Tenemos un problema con nuestros pedidos?

En grupos • 10–12 minutos

- Calculen el rango y la desviación estándar del valor de compra.
- Interpreten P25, P50 y P75.
- Describan la forma de la distribución.
- Identifiquen posibles valores atípicos.
- Escriban 3 frases que describan el comportamiento de compra.

Desafío

No usen solo números. Escriban una descripción que otra persona pueda entender.

Puesta en común · Reto 4

Centro

La mitad de la muestra está en $182.500 o menos; la media está elevada por la compra extrema.

Dispersión

El rango es muy amplio y la desviación estándar es alta en relación con el centro.

Forma

La distribución presenta una cola hacia valores altos y una observación de $1.200.000 que requiere revisión.

La estadística descriptiva empieza a convertirse en una historia sobre los datos.

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

05 ¿Qué podemos afirmar realmente?

Del dato aislado a una lectura útil para decidir.

El dato no habla solo

INDICADOR → **INTERPRETACIÓN** → **DECISIÓN**

Pregunta de control

¿Qué parte está directamente respaldada por los datos y qué parte estamos agregando nosotros?

Señal vs. ruido

VARIACIÓN NATURAL

Una caída del 2% de un día para otro puede ser una fluctuación normal, no necesariamente una crisis.

PREGUNTA

¿El cambio es suficientemente grande y consistente para considerarlo una señal?

No todo cambio merece una decisión.

El tamaño de la muestra importa

ANTES

1.000 usuarios
Conversión = 10%

→

AHORA

5 usuarios
Conversión = 50%

Cuidado

El cambio parece enorme, pero la segunda estimación se apoya en muy pocas observaciones.

Magnitud del cambio ≠ confiabilidad de la conclusión

Correlación ≠ causalidad

A ↑ ↕ B ↑

NO implica

A causó B

Antes de afirmar una causa

Considerar coincidencia, una tercera variable, estacionalidad o relación inversa. Para probar causalidad, se requieren diseños adecuados, como experimentos controlados.

Cada indicador tiene un alcance

LIKES ↑

Sí: mide reacción/interacción con un contenido.

No demuestra por sí solo: compras ↑, fidelidad ↑ o amor por la marca.

ROTACIÓN ↓

Sí: mide permanencia.

No demuestra por sí sola: motivación ↑ o productividad ↑.

Un indicador responde una pregunta concreta. No le pidamos responder otra.

Contexto y línea base cambian la lectura

50 quejas este mes **vs.** **150 quejas el mes pasado**

El mismo “50” puede parecer alto o representar una mejora importante, dependiendo de la línea base.

Estacionalidad

Vacaciones, festivos, cierres fiscales y otras dinámicas pueden mover los indicadores. Cuando corresponda, comparar con el mismo periodo anterior (YoY), no solo con el mes anterior (MoM).

Evitar el sesgo de confirmación

“Creo que la campaña funcionó”

Buscamos

Likes ↑
Alcance ↑
Seguidores ↑

Ignoramos

Conversión ↓
Costo ↑
Ventas ↔

Mejor práctica

Definir criterios de éxito y KPIs antes de mirar los resultados.

Reto 5 · ¿Tomamos la decisión?

En grupos • 10–12 minutos

A “El ticket promedio aumentó 15%, por lo tanto nuestros clientes están comprando más.”

B “Redes sociales tiene más clientes, por lo tanto es nuestro canal más efectivo.”

C “Los clientes con descuento compran más, por lo tanto el descuento genera mayores ventas.”

D “La satisfacción promedio es 4,2/5, por lo tanto todos nuestros clientes están satisfechos.”

Clasifiquen

🟢 Podemos afirmarlo

🟡 Necesitamos más información

🔴 Estamos sobreinterpretando

Puesta en común · Reto 5

🟢 Podemos afirmar

Lo que está directamente respaldado por los datos observados y por el alcance del indicador.

🟡 Necesitamos más información

La señal puede ser interesante, pero faltan contexto, volumen, comparación o variables.

🔴 Sobreinterpretamos

Afirmamos causas, generalizamos más allá de la muestra o atribuimos significados que el indicador no mide.

La buena analítica también consiste en saber decir: “esto todavía no lo podemos concluir”.

De los datos a la decisión

1 **IDENTIFICAR**
Variables, población y muestra

2 **CONTAR**
Frecuencias y proporciones

3 **RESUMIR**
Media, mediana y moda

4 **MEDIR**
Rango, varianza y desviación estándar

5 **UBICAR**
Percentiles

6 **OBSERVAR**
Distribuciones y valores atípicos

7 **CUESTIONAR**
Qué podemos y no podemos afirmar

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación

SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín

Esumer
Educación Superior

El producto final del caso

DESCRIBIR

Variables relevantes
Población y muestra
Frecuencias

RESUMIR

Media / mediana / moda
Dispersión
Percentiles
Distribución

INTERPRETAR

2 hallazgos
1 conclusión respaldada
1 conclusión que no podemos hacer

El análisis no termina en el número: termina en una interpretación responsable.

Una última pregunta

¿Qué decisión tomarías si solo tuvieras

el promedio?

¿Y qué decisión tomarías después de conocer también la distribución, la dispersión, el contexto y el alcance del indicador?

La estadística descriptiva no reemplaza el juicio: lo hace más informado.

Anexo · Dataset del caso

30 clientes · comercio electrónico

Variable	Tipo	Uso en clase
Edad	Cuantitativa discreta	Clasificación
Ciudad	Cualitativa nominal	Clasificación
Canal de adquisición	Cualitativa nominal	Frecuencias
Tipo de cliente	Cualitativa nominal	Comparación
Compras últimos 90 días	Cuantitativa discreta	Conteos
Valor última compra	Cuantitativa continua	Centro + dispersión
Días de entrega	Cuantitativa discreta	Frecuencias acumuladas
Satisfacción	Cualitativa ordinal	Interpretación
Descuento (%)	Cuantitativa continua	Correlación/causalidad
Recompró	Cualitativa dicotómica	Indicador de resultado

El archivo Excel adjunto contiene los 30 registros y un diccionario de variables.

Alcaldía de Medellín
Distrito de
Ciencia, Tecnología e Innovación
SAPIENCIA
Agencia de Educación
Postsecundaria de Medellín
Esumer
Educación Superior

Anexo docente · Respuestas rápidas

Bloque	Resultado / idea clave
Reto 1	Unidad = cliente; población = 1.000; muestra = 30. Clasificaciones en el diccionario.
Reto 2	Redes sociales = 10 (33,3%); Google = 10 (33,3%); Referidos = 6 (20%); Email = 4 (13,3%).
Reto 3	Media = $217.833; mediana = $182.500; moda = $90.000. La media está afectada por $1.200.000.
Reto 4	Rango = $1.130.000; DE muestral ≈ $206.321; P25 ≈ $101.250; P50 = $182.500; P75 ≈ $257.500; sesgo a la derecha.
Reto 5	No generalizar más allá de la muestra; correlación no prueba causalidad; un indicador tiene un alcance específico; pedir contexto y línea base.

Nota: los cálculos pueden variar ligeramente según la herramienta y el método de cuantiles utilizado.